
用于知识密集型自然语言处理任务的检索增强生成

帕特里克·刘易斯^{†‡}，伊桑·佩雷斯*

亚历山德拉·皮克图斯[†]，法比奥·佩特罗尼[†]，弗拉基米尔·卡尔普欣[†]，纳曼·戈亚尔[†]，海因里希·屈特勒[†]

迈克·刘易斯[†]，温涛·易[†]，蒂姆·罗克塔舍尔^{†‡}，塞巴斯蒂安·里德尔^{†‡}，杜威·基拉[†]

[†] 脸书人工智能研究室；[‡] 伦敦大学学院；*纽约大学；plewis@fb.com

摘要

大型预训练语言模型已被证明能在其参数中存储事实性知识，并在下游自然语言处理任务上微调时取得了当前最优的结果。然而，它们访问和精确操纵知识的能力仍然有限，因此在知识密集型任务上，其性能落后于特定任务的架构。此外，为其决策提供出处并更新其世界知识仍然是开放的研究问题。具有可微访问机制以访问显式非参数记忆的预训练模型可以克服这个问题，但到目前为止仅针对抽取式下游任务进行了研究。我们探索了一种用于检索增强生成（RAG）模型的通用微调方法，该模型结合了用于语言生成的预训练参数化记忆和非参数记忆。我们引入了RAG模型，其中参数化记忆是一个预训练的序列到序列（seq2seq）模型，非参数记忆是维基百科的密集向量索引，通过预训练的神经检索器进行访问。我们比较了两种RAG公式，一种是在整个生成序列中基于相同的检索段落进行条件设定，另一种是每个token可以使用不同的段落。我们在广泛的知识密集型自然语言处理任务上对我们的模型进行微调并评估，并在三个开放域问答任务上设定了当前最优的结果，优于参数化seq2seq模型和特定任务的检索与抽取架构。对于语言生成任务，我们发现RAG模型比仅使用参数化的最先进seq2seq基线生成更具体、更多样化和更具事实性的语言。

1 引言

预训练神经语言模型已被证明能从数据中学习大量深入的知识[47]。它们可以在不访问任何外部记忆的情况下做到这一点，作为一个参数化的隐式知识库[51, 52]。虽然这一发展令人兴奋，但这类模型确实有缺点：它们不能轻易扩展或修改其记忆，不能直接深入了解其预测，并且可能会产生“幻觉”[38]。将参数化记忆与非参数（即基于检索的）记忆相结合的混合模型[20, 26, 48]可以解决其中一些问题，因为知识可以直接修改和扩展，并且可以检查和解释所访问的知识。REALM[20]和ORQA[31]，这两个最近引入的将掩码语言模型[8]与可微检索器相结合的模型，已经显示出了有前景的结果，




图1: 我们方法的概述。我们将一个预训练的检索器（查询编码器 + 文档索引）与一个预训练的 seq2seq 模型（生成器）相结合，并进行端到端的微调。对于查询 x ，我们使用最大内积搜索（MIPS）来找到前 K 个文档 z_i 。对于最终预测 y ，我们将 z 视为一个潜在变量，并在给定不同文档的 seq2seq 预测上进行边缘化。

但仅探索了开放域抽取式问答。在这里，我们将参数化和非参数化的混合记忆引入到“自然语言处理的主力军”，即序列到序列（seq2seq）模型中。

我们通过一种通用的微调方法，即检索增强生成（RAG），为预训练的参数化记忆生成模型赋予非参数化记忆。我们构建了 RAG 模型，其中参数化记忆是一个预训练的 seq2seq 变换器，非参数化记忆是维基百科的密集向量索引，通过预训练的神经检索器进行访问。我们将这些组件组合在一个端到端训练的概率模型中（图1）。检索器（密集段落检索器[26]，以下简称 DPR）根据输入提供潜在文档，然后 seq2seq 模型（BART[32]）根据这些潜在文档以及输入来生成输出。我们通过 top-K 近似对潜在文档进行边缘化，要么按每个输出进行（假设同一文档负责所有令牌），要么按每个令牌进行（不同文档负责不同令牌）。与 T5[51] 或 BART 一样，RAG 可以在任何 seq2seq 任务上进行微调，从而同时学习生成器和检索器。

之前有大量工作提出了用于用非参数化记忆丰富系统的架构，这些架构是针对特定任务从零开始训练的，例如记忆网络[64, 55]、堆叠增强网络[25]和记忆层[30]。相比之下，我们探索了一种设置，其中参数化和非参数化记忆组件都经过预训练并预加载了大量知识。至关重要的是，通过使用预训练的访问机制，无需额外训练就能具备访问知识的能力。

我们的结果突出了将参数化和非参数化记忆与生成相结合用于知识密集型任务的好处——这些任务如果没有外部知识源，人类很难合理地完成。我们的 RAG 模型在开放自然问题[29]、网络问题[3]和精选 Trec[2]上取得了领先成果，并且在 TriviaQA[24]上大大优于最近使用专门预训练目标的方法。尽管这些是提取式任务，但我们发现无约束生成优于以前的提取式方法。对于知识密集型生成，我们在 MS-MARCO[1]和危险问题生成上进行了实验，并且发现我们的模型生成的回答比 BART 基线更真实、具体和多样。对于 FEVER[56]事实核查，我们取得的结果与使用强大检索监督的领先流水线模型相差在 4.3% 以内。最后，我们证明随着世界的变化，可以替换非参数化记忆来更新模型的知识。

2 方法

我们探索 RAG 模型，该模型使用输入序列 x 来检索文本文档 z ，并在生成目标序列 y 时将它们用作附加上下文。如图1所示，我们的模型利用两个组件：(i) 一个带有参数 η 的检索器 $p_\eta(z|x)$ ，它在给定查询 x 时返回（top-K 截断）文本段落上的分布，以及 (ii) 一个由 x 参数化的生成器 $p_\theta(y_i|x, z, y_{1:i-1})$ 。

¹ 用于运行 RAG 实验的代码已作为 HuggingFace Transformers 库[66]的一部分开源，可在 <https://github.com/huggingface/transformers/blob/master/examples/rag/> 找到。RAG 模型的交互式演示可在 <https://huggingface.co/rag/> 找到。

由 θ 根据前 $i - 1$ 个令牌 $y_{1:i-1}$ 的上下文、原始输入 x 和检索到的段落 z 生成当前令牌。

为了端到端地训练检索器和生成器，我们将检索到的文档视为一个潜在变量。我们提出了两种模型，它们以不同方式对潜在文档进行边缘化，以生成生成文本上的分布。在一种方法 RAG-Sequence 中，模型使用同一文档来预测每个目标令牌。第二种方法 RAG-Token 可以根据不同文档预测每个目标令牌。在下面，我们正式介绍这两种模型，然后描述 p_η 和 p_θ 组件，以及训练和解码过程。

2.1 模型

RAG 序列模型 RAG 序列模型使用相同的检索文档来生成完整序列。从技术上讲，它将检索到的文档视为单个潜在变量，通过 top-K 近似将其边缘化以获得 seq2seq 概率 $p(y | x)$ 。具体来说，使用检索器检索前 K 个文档，生成器为每个文档生成输出序列概率，然后将这些概率边缘化。

$$p_{\text{RAG-Sequence}}(y|x) \approx \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) p_\theta(y|x, z) = \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) \prod_i^N p_\theta(y_i|x, z, y_{1:i-1})$$

RAG 词元模型 在 RAG 词元模型中，我们可以为每个目标词元绘制不同的潜在文档并相应地进行边缘化。这使得生成器在生成答案时可以从多个文档中选择内容。具体来说，使用检索器检索前 K 个文档，然后生成器为每个文档生成下一个输出词元的分布，在边缘化之前，对下一个输出词元重复此过程，形式上，我们定义：

$$p_{\text{RAG-Token}}(y|x) \approx \prod_i^N \sum_{z \in \text{top-}k(p(\cdot|x))} p_\eta(z|x) p_\theta(y_i|x, z_i, y_{1:i-1})$$

最后，我们注意到通过将目标类别视为长度为 1 的目标序列，RAG 可用于序列分类任务，在这种情况下，RAG 序列和 RAG 词元是等效的。

2.2 检索器：DPR

检索组件 $p_\eta(z | x)$ 基于 DPR [26]。DPR 采用双编码器架构：

$$p_\eta(z | x) \propto \exp(\mathbf{d}(z)^\top \mathbf{q}(x)) \quad \mathbf{d}(z) = \text{BERT}_d(z), \quad \mathbf{q}(x) = \text{BERT}_q(x)$$

其中 $\mathbf{d}(z)$ 是由 BERT_{BASE} 文档编码器[8]生成的文档的密集表示， $\mathbf{q}(x)$ 是由查询编码器生成的查询表示，该查询编码器也基于 BERT_{BASE}。计算前 k 个 $(p_\eta(\cdot | x))$ ，即具有最高先验概率 $p_\eta(z | x)$ 的 k 文档 z 列表，是一个最大内积搜索（MIPS）问题，可以在亚线性时间内近似求解[23]。我们使用来自 DPR 的预训练双编码器来初始化我们的检索器并构建文档索引。这个检索器经过训练以检索包含 TriviaQA [24] 问题和自然问题[29]答案的文档。我们将文档索引称为非参数内存。

2.3 生成器：BART

生成器组件 $p_\theta(y_i | x, z, y_{1:i-1})$ 可以使用任何编码器 - 解码器进行建模。我们使用 BART-large [32]，一个具有 4 亿参数的预训练 seq2seq 变压器[58]。为了在从 BART 生成时将输入 x 与检索到的内容 z 相结合，我们只需将它们连接起来。BART 使用去噪目标和各种不同的噪声函数进行预训练。它在各种生成任务上取得了领先的结果，并且优于同等规模的 T5 模型[32]。此后，我们将 BART 生成器参数 θ 称为参数内存。

2.4 训练

我们联合训练检索器和生成器组件，而不对应该检索什么文档进行任何直接监督。给定输入/输出对 (x_j, y_j) 的微调训练语料库，我们

使用Adam [28]的随机梯度下降最小化每个目标的负边际对数似然 $\sum_j -\log p(y_j | x_j)$ 。在训练期间更新文档编码器 BERT_d 成本很高，因为它需要像REALM在预训练期间[20]那样定期更新文档索引。我们发现这一步骤对于强大的性能不是必需的，并且保持文档编码器（和索引）固定，仅微调查询编码器 BERT_q 和BART生成器。

2.5 解码

在测试时，RAG序列和RAG词元需要不同的方法来近似 $\arg \max_y p(y | x)$ 。

拉格令牌 拉格令牌模型可以看作是一个具有转移概率的标准自回归序列到序列生成器：

$$p'_\theta(y_i | x, y_{1:i-1}) = \sum_{z \in \text{top-k}(p(\cdot | x))} p_\eta(z_i | x) p_\theta(y_i | x, z_i, y_{1:i-1})$$

为了进行解码，我们可以将 $p'_\theta(y_i | x, y_{1:i-1})$ 插入到一个标准的束搜索解码器中。

拉格序列 对于拉格序列，似然性 $p(y | x)$ 不会分解为传统的逐个令牌似然性，因此我们不能用单束搜索来解决它。相反，我们对每个文档 z 运行束搜索，使用 $p_\theta(y_i | x, z, y_{1:i-1})$ 对每个假设进行评分。这产生了一组假设 Y ，其中一些可能没有出现在所有文档的束中。为了估计一个假设 y 的概率，我们对每个文档 z 运行一次额外的前向传递，对于 y 没有出现在束中的文档，将生成器概率乘以 $p_\eta(z | x)$ ，然后对束的边际概率求和。我们将这种解码过程称为“彻底解码”。对于更长的输出序列， $|Y|$ 可能会变得很大，需要多次前向传递。为了更有效地解码，我们可以进一步近似，即 $p_\theta(y | x, z_i) \approx 0$ ，其中 y 不是从 x, z_i 进行束搜索时生成的。这避免了在生成候选集 Y 后运行额外前向传递的需要。我们将这种解码过程称为“快速解码”。

3 实验

我们在广泛的知识密集型任务中对拉格进行实验。对于所有实验，我们使用单个维基百科转储作为我们的非参数知识源。遵循Lee等人[31]和Karpukhin等人[26]的方法，我们使用2018年12月的转储。每个维基百科文章被分成不相交的100字块，总共形成2100万个文档。我们使用文档编码器为每个文档计算一个嵌入，并使用FAISS[23]构建一个单一的MIPS索引，采用分层可导航小世界近似进行快速检索[37]。在训练期间，我们为每个查询检索前 k 个文档。我们考虑 $k \in \{5, 10\}$ 用于训练，并使用开发数据在测试时设置 k 。我们现在讨论每个任务的实验细节。

3.1 开放域问答

开放域问答（QA）是知识密集型任务的一个重要实际应用和常见测试平台[20]。我们将问题和答案视为输入-输出文本对 (x, y) ，并通过直接最小化答案的负对数似然性来训练拉格。我们将拉格与流行的抽取式QA范式[5, 7, 31, 26]进行比较，在该范式中，答案是从检索到的文档中提取的跨度，主要依赖于非参数知识。我们还与“闭卷QA”方法[52]进行比较，该方法与拉格一样生成答案，但不利用检索，而是纯粹依赖于参数知识。我们考虑四个流行的开放域QA数据集：自然问题（NQ）[29]、琐事问答（TQA）[24]、网络问题（WQ）[3]和精选Trec（CT）[2]。由于CT和WQ较小，我们遵循DPR[26]的方法，用我们的NQ拉格模型初始化CT和WQ模型。我们使用与先前工作[31, 26]相同的训练/开发/测试分割，并报告精确匹配（EM）分数。对于TQA，为了与T5[52]进行比较，我们还在TQA维基测试集上进行评估。

3.2 抽象式问答

检索增强生成（RAG）模型可以超越简单的抽取式问答，通过自由形式的抽象文本生成来回答问题。为了在知识密集型环境中测试RAG的自然语言生成（NLG）能力，我们使用了MSMARCO NLG任务v2.1 [43]。该任务包括问题、为每个问题从搜索引擎检索到的十篇黄金段落，以及从检索到的段落中标注的完整句子答案。我们不使用提供的段落，仅使用问题和答案，将MSMARCO视为一个开放域抽象问答任务。MSMARCO有一些问题，如果不访问黄金段落，就无法以与参考答案匹配的方式回答，例如“What is the weather in Volcano, CA?”因此，如果不使用黄金段落，性能会更低。我们还注意到，仅使用维基百科无法回答一些MSMARCO问题。在这里，RAG可以依靠参数化知识来生成合理的回答。

MSMARCO作为一个开放域抽象问答任务。MSMARCO有一些问题，如果不访问黄金段落，就无法以与参考答案匹配的方式回答，例如“*What is the weather in Volcano, CA?*”所以如果不使用黄金段落，性能会更低。我们还注意到，一些MSMARCO问题仅使用维基百科无法回答。在这里，RAG可以依靠参数化知识来生成合理的回答。

3.3 危险边缘问题生成

为了评估RAG在非问答环境中的生成能力，我们研究开放域问题生成。我们不是使用标准开放域问答任务中的问题（这些问题通常由简短、简单的问题组成），而是提出了更具挑战性的生成危险边缘问题的任务。危险边缘是一种不同寻常的形式，包括根据关于某个实体的事实来猜测该实体。例如，“世界杯”是问题“*In 1986 Mexico scored as the first country to host this international sports competition twice.*”的答案。由于危险边缘问题是精确的事实陈述，根据答案实体生成危险边缘问题构成了一项具有挑战性的知识密集型生成任务。

我们使用来自SearchQA [10] 的划分，有100K个训练示例、14K个开发示例和27K个测试示例。由于这是一个新任务，我们训练了一个BART模型用于比较。按照 [67]，我们使用SQuAD调整后的Q-BLEU-1指标 [42] 进行评估。Q-BLEU是BLEU的一种变体，对匹配实体的权重更高，并且与问题生成的人工判断的相关性比标准指标更高。我们还进行了两次人工评估，一次评估生成的事实性，一次评估特异性。我们将事实性定义为一个陈述是否可以由可信的外部来源证实，将特异性定义为输入和输出之间的高度相互依赖 [33]。我们遵循最佳实践并使用成对比较评估 [34]。评估者会看到一个答案和两个生成的问题，一个来自BART，一个来自RAG。然后他们被要求从四个选项中选择一个——问题A更好，问题B更好，两个都好，或者两个都不好。

3.4 事实核查

FEVER [56] 要求对自然语言声明是否得到维基百科的支持或反驳，或者是否没有足够的信息来决定进行分类。该任务需要从维基百科中检索与声明相关的证据，然后对这些证据进行推理，以分类该声明是真、假还是仅从维基百科无法验证。FEVER是一个检索问题，同时也是一个具有挑战性的蕴含推理任务。它还为探索RAG模型处理分类而不是生成的能力提供了一个合适的测试平台。我们将FEVER类标签（支持、反驳或信息不足）映射到单个输出令牌，并直接使用声明-类别对进行训练。至关重要的是，与大多数其他处理FEVER的方法不同，我们不使用对检索到的证据的监督。在许多实际应用中，检索监督信号不可用，不需要这种监督的模型将适用于更广泛的任務。我们探索了两种变体：标准的三分类任务（支持/反驳/信息不足）和Thorne和Vlachos [57] 研究的二分类任务（支持/反驳）。在这两种情况下，我们都报告标签准确率。

4 结果

4.1 开放域问答

表1展示了RAG与当前最先进模型的结果。在所有四个开放域问答任务上，RAG都创造了新的最先进水平（仅在TQA的与T5可比的划分上）。RAG结合了“闭卷”（仅参数化）方法的生成灵活性和基于“开卷”检索方法的性能。与REALM和T5+SSM不同，RAG在没有昂贵的、专门的“显著跨度掩码”预训练 [20] 的情况下取得了优异的结果。值得注意的是，RAG的检索器是使用DPR的检索器初始化的，DPR的检索器在自然问题和琐事问答上使用了检索监督。RAG与DPR问答系统相比表现出色，DPR问答系统使用基于BERT的“交叉编码器”对文档进行重新排序，同时还有一个抽取式阅读器。RAG表明，对于达到最先进的性能，重新排序器和抽取式阅读器都不是必需的。

即使有可能提取答案，生成答案也有几个优点。包含答案线索但未逐字包含答案的文档仍可为生成正确答案做出贡献，这是标准提取方法无法做到的，从而导致

表1: 开放域问答测试分数。对于TQA, 左列使用开放域问答的标准测试集, 右列使用TQA - Wiki测试集。更多细节见附录D。

	Model	NQ	TQA	WQ	CT
Closed Book	T5-11B [52]	34.5	- /50.1	37.4	-
	T5-11B+SSM [52]	36.6	- /60.5	44.7	-
Open Book	REALM [20]	40.4	- / -	40.7	46.8
	DPR [26]	41.5	57.9 / -	41.1	50.6
	RAG-Token	44.1	55.2/66.1	45.5	50.0
	RAG-Seq.	44.5	56.8/ 68.0	45.2	52.2

表2: 生成和分类测试分数。MS - MARCO SotA是[4], FEVER - 3是[68], FEVER - 2是[57] *使用黄金上下文/证据。无黄金访问权限下的最佳模型加下划线。

Model	Jeopardy B-1	QB-1	MSMARCO R-L	B-1	FVR3 Label	FVR2 Acc.
SotA	-	-	49.8*	49.9*	76.8	92.2*
BART	15.1	19.7	38.2	41.6	64.0	81.1
RAG-Tok.	17.3	22.2	40.1	41.5	72.5	<u>89.5</u>
RAG-Seq.	14.7	21.4	<u>40.8</u>	<u>44.2</u>		

对文档进行更有效的边缘化。此外, 即使正确答案不在任何检索到的文档中, RAG也可以生成正确答案, 在这种情况下, NQ的准确率达到11.8%, 而提取模型的得分将为0%。

4.2 摘要式问答

如表2所示, RAG - Sequence在开放MS - MARCO NLG上比BART高出2.6个Bleu分数和2.6个Rouge - L分数。RAG方法达到了当前的模型性能, 考虑到 (i) 那些模型可以访问带有生成参考答案所需特定信息的黄金段落, (ii) 许多问题没有黄金段落就无法回答, 以及 (iii) 并非所有问题仅从维基百科就能回答, 这令人印象深刻。表3展示了我们模型生成的一些答案。定性地说, 我们发现RAG模型比BART更少产生幻觉, 并且更频繁地生成事实正确的文本。稍后, 我们还表明RAG生成的内容比BART生成的内容更多样化 (见§4.5)。

4.3 危险边缘问题生成

表2表明, 在危险边缘问题生成方面, RAG - Token比RAG - Sequence表现更好, 两个模型在Q - BLEU - 1上都优于BART。表4展示了对来自BART和RAG - Token的452对生成内容的人工评估结果。评估者指出, 在仅7.1%的情况下, BART比RAG更符合事实, 而在42.7%的情况下, RAG更符合事实, 并且在另外17%的情况下, RAG和BART都符合事实, 这清楚地证明了RAG在该任务上相对于当前最先进的生成模型的有效性。评估者还发现RAG生成在很大程度上更具体。表3展示了每个模型的典型生成内容。

危险边缘问题通常包含两个独立的信息片段, RAG - Token可能表现最佳, 因为它可以生成结合多个文档内容的回答。图2展示了一个例子。当生成“Sun”时, 提到“The Sun Also Rises”的文档2的后验概率很高。同样, 当生成“A Farewell to Arms”时, 文档1在很大程度上主导了后验概率。有趣的是, 在生成每本书的第一个词之后, 文档后验概率趋于平稳。这一观察结果表明, 生成器可以在不依赖特定文档的情况下完成标题。换句话说, 模型的参数知识足以完成标题。我们通过将仅BART基线与部分解码“The Sun”进行输入来为这一假设找到证据。BART完成生成“The Sun Also Rises”是这部“The Sun Also Rises”作者的小说, 表明标题“The Sun Also Rises”存储在BART的参数中。同样, BART将完成部分解码“The Sun Also Rises”是这部“A”作者的小说为“The Sun Also Rises”是这部“A Farewell to Arms”作者的小说。这个例子展示了参数化和非参数化记忆是如何协同工作的——非参数化组件有助于指导生成, 提取存储在参数化记忆中的特定知识。

4.4 事实验证

表2展示了我们在FEVER上的结果。对于三分类, RAG分数与当前最先进的模型相差在4.3%以内, 那些模型是具有特定领域架构和大量工程的复杂管道系统, 使用中间检索监督进行训练, 而RAG不需要这些。




图2: 在为《危险边缘》生成任务检索5篇文档的情况下，对于输入“Hemingway”生成的每个token，RAG-Token文档后验概率 $p(z_i | x, y_i, y_{-i})$ 。在生成“A Farewell to Arms”时，文档1的后验概率较高；在生成“The Sun Also Rises”时，文档2的后验概率较高。

表3: 生成任务的示例。RAG模型生成的回答更具体且事实准确。“?”表示事实错误的回答，“*”表示部分正确的回答。

Task	Input	Model	Generation
MS-MARCO	define middle ear	BART	?The middle ear is the part of the ear between the middle ear and the nose.
		RAG-T	The middle ear is the portion of the ear internal to the eardrum.
		RAG-S	The middle ear includes the tympanic cavity and the three ossicles.
	what currency needed in scotland	BART	The currency needed in Scotland is Pound sterling.
		RAG-T	Pound is the currency needed in Scotland.
		RAG-S	The currency needed in Scotland is the pound sterling.
Jeopardy Question Generation	Washington	BART	?This state has the largest number of counties in the U.S.
		RAG-T	It's the only U.S. state named for a U.S. president
		RAG-S	It's the state where you'll find Mount Rainier National Park
	The Divine Comedy	BART	*This epic poem by Dante is divided into 3 parts: the Inferno, the Purgatorio & the Purgatorio
		RAG-T	Dante's "Inferno" is the first part of this epic poem
		RAG-S	This 14th century work is divided into 3 sections: "Inferno", "Purgatorio" & "Paradiso"

对于二分类任务，我们与Thorne和Vlachos [57]进行比较，他们训练RoBERTa [35]根据给定的黄金证据句子将声明分类为真或假。尽管RAG仅被提供声明并自行检索证据，但它的准确率与该模型相差在2.7%以内。我们还分析了RAG检索到的文档是否与FEVER中注释为黄金证据的文档相对应。我们计算了RAG检索到的前 k 篇文档与黄金证据注释之间文章标题的重叠率。我们发现，在 71% 的情况下，检索到的第一篇文档来自黄金文章，在 90% 的情况下，黄金文章出现在前10篇检索到的文章中。

4.5 其他结果

生成多样性 第4.3节表明，对于《危险边缘》问题生成任务，RAG模型比BART更注重事实且更具体。遵循最近关于促进多样性解码的工作[33, 59, 39]，我们还通过计算不同模型生成的不同 n 元语法与总 n 元语法的比率来研究生成多样性。表5表明，RAG-Sequence的生成结果比RAG-Token更多样化，并且两者都比BART明显更多样化，而无需任何促进多样性的解码。

检索消融 RAG的一个关键特性是学习为任务检索相关信息。为了评估检索机制的有效性，我们进行消融实验，在训练期间冻结检索器。如表6所示，学习检索提高了所有任务的结果。我们将RAG的密集检索器与基于词重叠的BM25检索器[53]进行比较。在这里，我们用固定的BM25系统替换RAG的检索器，并在计算 $p(z | x)$ 时使用BM25检索分数作为对数几率。表6显示了结果。对于FEVER，BM25表现最佳，可能是因为FEVER声明严重以实体为中心，因此非常适合基于词重叠的检索。可微检索提高了所有其他任务的结果，特别是对于开放域问答，这一点至关重要。

索引热插拔 像RAG这样的非参数记忆模型的一个优点是，在测试时知识可以很容易地更新。像T5或BART这样的仅参数模型需要进一步训练才能随着世界的变化更新其行为。为了证明这一点，我们使用2016年12月DrQA [5]的维基百科转储构建一个索引，并将使用此索引的RAG输出与我们主要结果（2018年12月）中的新索引进行比较。我们准备了一份在这些日期之间发生变化的82位世界领导人的列表，并使用模板“谁是{职位}?”（例如“谁是秘鲁总统?”）

表4: 《危险边缘》问题生成任务的人工评估。

	Factuality	Specificity
BART better	7.1%	16.8%
RAG better	42.7%	37.4%
Both good	11.7%	11.8%
Both poor	17.7%	6.9%
No majority	20.8%	20.1%

表5: 生成任务中不同三元语法与总三元语法的比率。

	MSMARCO	Jeopardy QGen
Gold	89.6%	90.0%
BART	70.7%	32.4%
RAG-Token	77.8%	46.8%
RAG-Seq.	83.5%	53.8%

表6: 开发集上的消融实验。由于FEVER 是一个分类任务, 两个RAG 模型是等效的。

Model	NQ	TQA	WQ	CT	Jeopardy-QGen		MSMarco		FVR-3	FVR-2
		Exact Match			B-1	QB-1	R-L	B-1	Label Accuracy	
RAG-Token-BM25	29.7	41.5	32.1	33.1	17.5	22.3	55.5	48.4	75.1	91.6
RAG-Sequence-BM25	31.8	44.1	36.6	33.8	11.1	19.5	56.5	46.9		
RAG-Token-Frozen	37.8	50.1	37.1	51.1	16.7	21.7	55.9	49.4	72.9	89.4
RAG-Sequence-Frozen	41.2	52.1	41.8	52.6	11.8	19.6	56.7	47.3		
RAG-Token	43.5	54.8	46.5	51.9	17.9	22.6	56.2	49.4	74.5	90.6
RAG-Sequence	44.0	55.8	44.9	53.4	15.3	21.5	57.2	47.5		

使用每个索引查询我们的NQ RAG模型。对于2016年的世界领导人, RAG使用2016年索引的回答正确率为70%, 对于2018年的世界领导人, 使用2018年索引的回答正确率为68%。使用不匹配索引时的准确率较低(使用2018年索引和2016年领导人时为12%, 使用2016年索引和2018年领导人时为4%)。这表明我们可以通过简单地替换其非参数记忆来更新RAG的世界知识。

检索更多文档的效果 模型使用5篇或10篇检索到的潜在文档进行训练, 我们没有观察到它们在性能上的显著差异。我们可以在测试时灵活调整检索到的文档数量, 这可能会影响性能和运行时间。图3(左)表明, 在测试时检索更多文档会单调提高RAG-Sequence的开放域问答结果, 但对于RAG-Token, 在检索10篇文档时性能达到峰值。图3(右)表明, 检索更多文档会以牺牲Bleu-1为代价提高RAG-Token的Rouge-L, 但对RAG-Sequence的影响不太明显。




图3: 左图: 随着检索的文档数量增加, NQ性能情况。中图: NQ中的检索召回性能。右图: 随着检索的文档数量增加, MS-MARCO的Bleu-1和Rouge-L情况。

5 相关工作

单任务检索 先前的工作表明, 孤立地考虑检索时, 它能提高各种自然语言处理任务的性能。这些任务包括开放域问答[5, 29]、事实验证[56]、事实补全[48]、长篇问答[12]、维基百科文章生成[36]、对话[41, 65, 9, 13]、翻译[17]以及语言建模[19, 27]。我们的工作统一了先前将检索纳入单个任务的成功经验, 表明基于单一检索的架构能够在多个任务中取得优异性能。

自然语言处理的通用架构 先前关于自然语言处理任务通用架构的工作在不使用检索的情况下取得了巨大成功。一个经过预训练的单一语言模型在微调[49, 8]后, 已在GLUE基准测试[60, 61]中的各种分类任务上表现出色。GPT-2[50]后来表明, 一个从左到右的单一预训练语言模型可以在判别式任务和生成式任务中都取得优异性能。为了进一步改进, BART[32]和T5[51, 52]提出了一个单一的预训练编码器 - 解码器模型, 该模型利用双向注意力在判别式任务和生成式任务中取得更强的性能。我们的工作旨在通过学习一个检索模块来增强预训练的生成式语言模型, 以单一统一架构扩展可能的任务空间。

学习检索 在信息检索中, 特别是在与我们类似的预训练神经语言模型[44, 26]方面, 有大量关于学习检索文档的工作。一些工作优化检索模块以辅助特定的下游任务, 如问答, 使用搜索[46]、强化学习[6, 63, 62]或我们工作中使用的潜在变量方法[31, 20]。这些成功利用了不同的基于检索的架构和优化技术在单个任务上取得优异性能, 而我们表明基于单一检索的架构可以针对各种任务进行微调以获得优异性能。

基于记忆的架构 我们的文档索引可以看作是神经网络可关注的大型外部记忆, 类似于记忆网络[64, 55]。同时期的工作[14]学习为输入中的每个实体检索一个训练好的嵌入, 而不是像我们的工作那样检索原始文本。其他工作通过关注事实嵌入[9, 13]或更接近我们工作的直接关注检索到的文本[15]来提高对话模型生成事实性文本的能力。我们记忆的一个关键特征是它由原始文本而非分布式表示组成, 这使得记忆既 (i) 对人类可读, 为我们的模型提供了一种可解释性形式, 又 (ii) 对人类可写, 使我们能够通过编辑文档索引动态更新模型的记忆。

检索与编辑方法 我们的方法与检索与编辑风格的方法有一些相似之处, 即针对给定输入检索相似的训练输入 - 输出对, 然后进行编辑以提供最终输出。这些方法在包括机器翻译[18, 22]和语义解析[21]在内的多个领域已被证明是成功的。我们的方法确实有几个不同之处, 包括较少强调对检索到的项目进行轻微编辑, 而是强调聚合来自多个检索到的内容的信息, 以及学习潜在检索, 并检索证据文档而非相关训练对。话虽如此, RAG技术在这些设置中可能效果良好, 并且可能代表有前途的未来工作。

6 讨论

在这项工作中, 我们展示了可访问参数化和非参数化记忆的混合生成模型。我们表明我们的RAG模型在开放域问答中取得了领先成果。我们发现人们更喜欢RAG的生成结果而不是纯粹参数化的BART, 认为RAG更具事实性和具体性。我们对学习到的检索组件进行了全面研究, 验证了其有效性, 并说明了如何热插拔检索索引以更新模型而无需任何重新训练。在未来的工作中, 研究这两个组件是否可以从零开始联合预训练可能会有成果, 无论是使用类似于BART的去噪目标还是其他目标。我们的工作开辟了关于参数化和非参数化记忆如何相互作用以及如何最有效地结合它们的新研究方向, 在应用于各种自然语言处理任务方面显示出前景。

更广泛的影响

与之前的工作相比，这项工作带来了一些积极的社会效益：它更牢固地扎根于真实的事实性知识（在这种情况下是维基百科），这使得它在生成更符合事实的内容时“幻觉”更少，并且提供了更多的可控性和可解释性。RAG可用于各种对社会有直接益处的场景，例如为其赋予医学索引并就该主题向其提出开放域问题，或者帮助人们在工作中更高效。

这些优势也伴随着潜在的缺点：维基百科或任何潜在的外部知识来源可能永远不会完全真实且完全没有偏见。由于RAG可以用作语言模型，这里与GPT-2[50]类似的担忧是合理的，尽管可以说程度较轻，包括它可能被用于在新闻或社交媒体上生成辱骂、虚假或误导性内容；用于冒充他人；或用于自动化垃圾邮件/网络钓鱼内容的制作[54]。先进的语言模型在未来几十年也可能导致各种工作的自动化[16]。为了减轻这些风险，可以使用人工智能系统来对抗误导性内容和自动化垃圾邮件/网络钓鱼。

致谢

作者要感谢审稿人对本文提出的深思熟虑且富有建设性的反馈，以及HuggingFace在开源运行RAG模型的代码方面提供的帮助。作者还要感谢Kyunghyun Cho和Sewon Min进行的富有成效的讨论和建议。

资金披露

EP感谢美国国家科学基金会研究生研究奖学金的支持。PL由FAIR博士项目资助。这项工作由Facebook资助。

参考文献

- [1] Payal Bajaj, Daniel Campos, Nick Craswell, Li Deng, Jianfeng Gao, Xiaodong Liu, Rangan Majumder, Andrew McNamara, Bhaskar Mitra, Tri Nguyen, Mir Rosenberg, Xia Song, Alina Stoica, Saurabh Tiwary, and Tong Wang. MS MARCO: A Human Generated MACHine Reading COMprehension Dataset. *arXiv:1611.09268 [cs]*, November 2016. URL <http://arxiv.org/abs/1611.09268>. arXiv: 1611.09268.
- [2] Petr Baudiš and Jan Šedivý. Modeling of the question answering task in the yodaqa system. In *International Conference of the Cross-Language Evaluation Forum for European Languages*, pages 222–228. Springer, 2015. URL https://link.springer.com/chapter/10.1007/978-3-319-24027-5_20.
- [3] Jonathan Berant, Andrew Chou, Roy Frostig, and Percy Liang. Semantic Parsing on Freebase from Question-Answer Pairs. In *Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*, pages 1533–1544, Seattle, Washington, USA, October 2013. Association for Computational Linguistics. URL <http://www.aclweb.org/anthology/D13-1160>.
- [4] Bin Bi, Chenliang Li, Chen Wu, Ming Yan, and Wei Wang. Palm: Pre-training an autoencoding&autoregressive language model for context-conditioned generation. *ArXiv*, abs/2004.07159, 2020. URL <https://arxiv.org/abs/2004.07159>.
- [5] Danqi Chen, Adam Fisch, Jason Weston, and Antoine Bordes. Reading Wikipedia to Answer Open-Domain Questions. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1870–1879, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1171. URL <https://www.aclweb.org/anthology/P17-1171>.
- [6] Eunsol Choi, Daniel Hewlett, Jakob Uszkoreit, Illia Polosukhin, Alexandre Lacoste, and Jonathan Berant. Coarse-to-fine question answering for long documents. In *Proceedings of the*

- 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 209–220, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1020. URL <https://www.aclweb.org/anthology/P17-1020>.
- [7] Christopher Clark and Matt Gardner. Simple and Effective Multi-Paragraph Reading Comprehension. *arXiv:1710.10723 [cs]*, October 2017. URL <http://arxiv.org/abs/1710.10723>. arXiv: 1710.10723.
 - [8] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-1423. URL <https://www.aclweb.org/anthology/N19-1423>.
 - [9] Emily Dinan, Stephen Roller, Kurt Shuster, Angela Fan, Michael Auli, and Jason Weston. Wizard of wikipedia: Knowledge-powered conversational agents. In *International Conference on Learning Representations*, 2019. URL <https://openreview.net/forum?id=r1l73iRqKm>.
 - [10] Matthew Dunn, Levent Sagun, Mike Higgins, V. Ugur Guney, Volkan Cirik, and Kyunghyun Cho. SearchQA: A New Q&A Dataset Augmented with Context from a Search Engine. *arXiv:1704.05179 [cs]*, April 2017. URL <http://arxiv.org/abs/1704.05179>. arXiv: 1704.05179.
 - [11] Angela Fan, Mike Lewis, and Yann Dauphin. Hierarchical neural story generation. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 889–898, Melbourne, Australia, July 2018. Association for Computational Linguistics. doi: 10.18653/v1/P18-1082. URL <https://www.aclweb.org/anthology/P18-1082>.
 - [12] Angela Fan, Yacine Jernite, Ethan Perez, David Grangier, Jason Weston, and Michael Auli. ELI5: Long form question answering. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3558–3567, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1346. URL <https://www.aclweb.org/anthology/P19-1346>.
 - [13] Angela Fan, Claire Gardent, Chloe Braud, and Antoine Bordes. Augmenting transformers with KNN-based composite memory, 2020. URL <https://openreview.net/forum?id=H1gx1CNKPH>.
 - [14] Thibault Févry, Livio Baldini Soares, Nicholas FitzGerald, Eunsol Choi, and Tom Kwiatkowski. Entities as experts: Sparse memory access with entity supervision. *ArXiv*, abs/2004.07202, 2020. URL <https://arxiv.org/abs/2004.07202>.
 - [15] Marjan Ghazvininejad, Chris Brockett, Ming-Wei Chang, Bill Dolan, Jianfeng Gao, Wen tau Yih, and Michel Galley. A knowledge-grounded neural conversation model. In *AAAI Conference on Artificial Intelligence*, 2018. URL <https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/16710>.
 - [16] Katja Grace, John Salvatier, Allan Dafoe, Baobao Zhang, and Owain Evans. When will AI exceed human performance? evidence from AI experts. *CoRR*, abs/1705.08807, 2017. URL <http://arxiv.org/abs/1705.08807>.
 - [17] Jiatao Gu, Yong Wang, Kyunghyun Cho, and Victor O.K. Li. Search engine guided neural machine translation. In *AAAI Conference on Artificial Intelligence*, 2018. URL <https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/17282>.
 - [18] Jiatao Gu, Yong Wang, Kyunghyun Cho, and Victor O.K. Li. Search engine guided neural machine translation. In *32nd AAAI Conference on Artificial Intelligence, AAAI 2018*, 32nd AAAI Conference on Artificial Intelligence, AAAI 2018, pages 5133–5140. AAAI press, 2018. 32nd AAAI Conference on Artificial Intelligence, AAAI 2018 ; Conference date: 02-02-2018 Through 07-02-2018.

- [19] Kelvin Guu, Tatsunori B. Hashimoto, Yonatan Oren, and Percy Liang. Generating sentences by editing prototypes. *Transactions of the Association for Computational Linguistics*, 6:437–450, 2018. doi: 10.1162/tacl_a_00030. URL <https://www.aclweb.org/anthology/Q18-1031>.
- [20] Kelvin Guu, Kenton Lee, Zora Tung, Panupong Pasupat, and Ming-Wei Chang. REALM: Retrieval-augmented language model pre-training. *ArXiv*, abs/2002.08909, 2020. URL <https://arxiv.org/abs/2002.08909>.
- [21] Tatsunori B Hashimoto, Kelvin Guu, Yonatan Oren, and Percy S Liang. A retrieve-and-edit framework for predicting structured outputs. In S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi, and R. Garnett, editors, *Advances in Neural Information Processing Systems 31*, pages 10052–10062. Curran Associates, Inc., 2018. URL <http://papers.nips.cc/paper/8209-a-retrieve-and-edit-framework-for-predicting-structured-outputs.pdf>.
- [22] Nabil Hossain, Marjan Ghazvininejad, and Luke Zettlemoyer. Simple and effective retrieve-edit-rerank text generation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 2532–2538, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.228. URL <https://www.aclweb.org/anthology/2020.acl-main.228>.
- [23] Jeff Johnson, Matthijs Douze, and Hervé Jégou. Billion-scale similarity search with gpus. *arXiv preprint arXiv:1702.08734*, 2017. URL <https://arxiv.org/abs/1702.08734>.
- [24] Mandar Joshi, Eunsol Choi, Daniel Weld, and Luke Zettlemoyer. TriviaQA: A Large Scale Distantly Supervised Challenge Dataset for Reading Comprehension. In *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1601–1611, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1147. URL <https://www.aclweb.org/anthology/P17-1147>.
- [25] Armand Joulin and Tomas Mikolov. Inferring algorithmic patterns with stack-augmented recurrent nets. In *Proceedings of the 28th International Conference on Neural Information Processing Systems - Volume 1, NIPS’15*, page 190–198, Cambridge, MA, USA, 2015. MIT Press. URL <https://papers.nips.cc/paper/5857-inferring-algorithmic-patterns-with-stack-augmented-recurrent-nets>.
- [26] Vladimir Karpukhin, Barlas Oguz, Sewon Min, Ledell Wu, Sergey Edunov, Danqi Chen, and Wen-tau Yih. Dense passage retrieval for open-domain question answering. *arXiv preprint arXiv:2004.04906*, 2020. URL <https://arxiv.org/abs/2004.04906>.
- [27] Urvashi Khandelwal, Omer Levy, Dan Jurafsky, Luke Zettlemoyer, and Mike Lewis. Generalization through memorization: Nearest neighbor language models. In *International Conference on Learning Representations*, 2020. URL <https://openreview.net/forum?id=HklBjCEKvH>.
- [28] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015. URL <http://arxiv.org/abs/1412.6980>.
- [29] Tom Kwiatkowski, Jennimaria Palomaki, Olivia Redfield, Michael Collins, Ankur Parikh, Chris Alberti, Danielle Epstein, Illia Polosukhin, Matthew Kelcey, Jacob Devlin, Kenton Lee, Kristina N. Toutanova, Llion Jones, Ming-Wei Chang, Andrew Dai, Jakob Uszkoreit, Quoc Le, and Slav Petrov. Natural Questions: a Benchmark for Question Answering Research. *Transactions of the Association of Computational Linguistics*, 2019. URL <https://tomkwiat.users.x20web.corp.google.com/papers/natural-questions/main-1455-kwiatkowski.pdf>.
- [30] Guillaume Lample, Alexandre Sablayrolles, Marc’ Aurelio Ranzato, Ludovic Denoyer, and Herve Jegou. Large memory layers with product keys. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d’ Alché-Buc, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 8548–8559. Curran Associates, Inc., 2019. URL <http://papers.nips.cc/paper/9061-large-memory-layers-with-product-keys.pdf>.

- [31] Kenton Lee, Ming-Wei Chang, and Kristina Toutanova. Latent retrieval for weakly supervised open domain question answering. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 6086–6096, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1612. URL <https://www.aclweb.org/anthology/P19-1612>.
- [32] Mike Lewis, Yinhan Liu, Naman Goyal, Marjan Ghazvininejad, Abdelrahman Mohamed, Omer Levy, Veselin Stoyanov, and Luke Zettlemoyer. BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. *arXiv preprint arXiv:1910.13461*, 2019. URL <https://arxiv.org/abs/1910.13461>.
- [33] Jiwei Li, Michel Galley, Chris Brockett, Jianfeng Gao, and Bill Dolan. A diversity-promoting objective function for neural conversation models. In *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 110–119, San Diego, California, June 2016. Association for Computational Linguistics. doi: 10.18653/v1/N16-1014. URL <https://www.aclweb.org/anthology/N16-1014>.
- [34] Margaret Li, Jason Weston, and Stephen Roller. Acute-eval: Improved dialogue evaluation with optimized questions and multi-turn comparisons. *ArXiv*, abs/1909.03087, 2019. URL <https://arxiv.org/abs/1909.03087>.
- [35] Hairong Liu, Mingbo Ma, Liang Huang, Hao Xiong, and Zhongjun He. Robust neural machine translation with joint textual and phonetic embedding. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pages 3044–3049, Florence, Italy, July 2019. Association for Computational Linguistics. doi: 10.18653/v1/P19-1291. URL <https://www.aclweb.org/anthology/P19-1291>.
- [36] Peter J. Liu*, Mohammad Saleh*, Etienne Pot, Ben Goodrich, Ryan Sepassi, Lukasz Kaiser, and Noam Shazeer. Generating wikipedia by summarizing long sequences. In *International Conference on Learning Representations*, 2018. URL <https://openreview.net/forum?id=Hyg0vbWC->.
- [37] Yury A. Malkov and D. A. Yashunin. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42:824–836, 2016. URL <https://arxiv.org/abs/1603.09320>.
- [38] Gary Marcus. The next decade in ai: four steps towards robust artificial intelligence. *arXiv preprint arXiv:2002.06177*, 2020. URL <https://arxiv.org/abs/2002.06177>.
- [39] Luca Massarelli, Fabio Petroni, Aleksandra Piktus, Myle Ott, Tim Rocktäschel, Vassilis Plachouras, Fabrizio Silvestri, and Sebastian Riedel. How decoding strategies affect the verifiability of generated text. *arXiv preprint arXiv:1911.03587*, 2019. URL <https://arxiv.org/abs/1911.03587>.
- [40] Paulius Micikevicius, Sharan Narang, Jonah Alben, Gregory Diamos, Erich Elsen, David Garcia, Boris Ginsburg, Michael Houston, Oleksii Kuchaiev, Ganesh Venkatesh, and Hao Wu. Mixed precision training. In *ICLR*, 2018. URL <https://openreview.net/forum?id=r1gs9JgRZ>.
- [41] Nikita Moghe, Siddhartha Arora, Suman Banerjee, and Mitesh M. Khapra. Towards exploiting background knowledge for building conversation systems. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 2322–2332, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1255. URL <https://www.aclweb.org/anthology/D18-1255>.
- [42] Preksha Nema and Mitesh M. Khapra. Towards a better metric for evaluating question generation systems. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pages 3950–3959, Brussels, Belgium, October-November 2018. Association for Computational Linguistics. doi: 10.18653/v1/D18-1429. URL <https://www.aclweb.org/anthology/D18-1429>.

- [43] Tri Nguyen, Mir Rosenberg, Xia Song, Jianfeng Gao, Saurabh Tiwary, Rangan Majumder, and Li Deng. MS MARCO: A human generated machine reading comprehension dataset. In Tarek Richard Besold, Antoine Bordes, Artur S. d’Avila Garcez, and Greg Wayne, editors, *Proceedings of the Workshop on Cognitive Computation: Integrating neural and symbolic approaches 2016 co-located with the 30th Annual Conference on Neural Information Processing Systems (NIPS 2016), Barcelona, Spain, December 9, 2016*, volume 1773 of *CEUR Workshop Proceedings*. CEUR-WS.org, 2016. URL http://ceur-ws.org/Vol-1773/CoCoNIPS_2016_paper9.pdf.
- [44] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019. URL <https://arxiv.org/abs/1901.04085>.
- [45] Myle Ott, Sergey Edunov, Alexei Baevski, Angela Fan, Sam Gross, Nathan Ng, David Grangier, and Michael Auli. fairseq: A fast, extensible toolkit for sequence modeling. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (Demonstrations)*, pages 48–53, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/N19-4009. URL <https://www.aclweb.org/anthology/N19-4009>.
- [46] Ethan Perez, Siddharth Karamcheti, Rob Fergus, Jason Weston, Douwe Kiela, and Kyunghyun Cho. Finding generalizable evidence by learning to convince q&a models. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2402–2411, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1244. URL <https://www.aclweb.org/anthology/D19-1244>.
- [47] Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, and Alexander Miller. Language models as knowledge bases? In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, pages 2463–2473, Hong Kong, China, November 2019. Association for Computational Linguistics. doi: 10.18653/v1/D19-1250. URL <https://www.aclweb.org/anthology/D19-1250>.
- [48] Fabio Petroni, Patrick Lewis, Aleksandra Piktus, Tim Rocktäschel, Yuxiang Wu, Alexander H. Miller, and Sebastian Riedel. How context affects language models’ factual predictions. In *Automated Knowledge Base Construction*, 2020. URL <https://openreview.net/forum?id=025X0zPfn>.
- [49] Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving Language Understanding by Generative Pre-Training, 2018. URL https://s3-us-west-2.amazonaws.com/openai-assets/research-covers/language-unsupervised/language_understanding_paper.pdf.
- [50] Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners, 2019. URL https://d4mucfpksywv.cloudfront.net/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.
- [51] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *arXiv e-prints*, 2019. URL <https://arxiv.org/abs/1910.10683>.
- [52] Adam Roberts, Colin Raffel, and Noam Shazeer. How much knowledge can you pack into the parameters of a language model? *arXiv e-prints*, 2020. URL <https://arxiv.org/abs/2002.08910>.
- [53] Stephen Robertson and Hugo Zaragoza. The probabilistic relevance framework: Bm25 and beyond. *Found. Trends Inf. Retr.*, 3(4):333–389, April 2009. ISSN 1554-0669. doi: 10.1561/15000000019. URL <https://doi.org/10.1561/15000000019>.
- [54] Irene Solaiman, Miles Brundage, Jack Clark, Amanda Askell, Ariel Herbert-Voss, Jeff Wu, Alec Radford, and Jian-Bing Wang. Release strategies and the social impacts of language models. *ArXiv*, abs/1908.09203, 2019.

- [55] Sainbayar Sukhbaatar, Arthur Szlam, Jason Weston, and Rob Fergus. End-to-end memory networks. In C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, and R. Garnett, editors, *Advances in Neural Information Processing Systems 28*, pages 2440–2448. Curran Associates, Inc., 2015. URL <http://papers.nips.cc/paper/5846-end-to-end-memory-networks.pdf>
- [56] James Thorne, Andreas Vlachos, Christos Christodoulopoulos, and Arpit Mittal. FEVER: a large-scale dataset for fact extraction and VERification. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pages 809–819, New Orleans, Louisiana, June 2018. Association for Computational Linguistics. doi: 10.18653/v1/N18-1074. URL <https://www.aclweb.org/anthology/N18-1074>
- [57] James H. Thorne and Andreas Vlachos. Avoiding catastrophic forgetting in mitigating model biases in sentence-pair classification with elastic weight consolidation. *ArXiv*, abs/2004.14366, 2020. URL <https://arxiv.org/abs/2004.14366>
- [58] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In I. Guyon, U. V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, and R. Garnett, editors, *Advances in Neural Information Processing Systems 30*, pages 5998–6008. Curran Associates, Inc., 2017. URL <http://papers.nips.cc/paper/7181-attention-is-all-you-need.pdf>
- [59] Ashwin Vijayakumar, Michael Cogswell, Ramprasaath Selvaraju, Qing Sun, Stefan Lee, David Crandall, and Dhruv Batra. Diverse beam search for improved description of complex scenes. *AAAI Conference on Artificial Intelligence*, 2018. URL <https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/17329>
- [60] Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. GLUE: A multi-task benchmark and analysis platform for natural language understanding. In *Proceedings of the 2018 EMNLP Workshop BlackboxNLP: Analyzing and Interpreting Neural Networks for NLP*, pages 353–355, Brussels, Belgium, November 2018. Association for Computational Linguistics. doi: 10.18653/v1/W18-5446. URL <https://www.aclweb.org/anthology/W18-5446>
- [61] Alex Wang, Yada Pruksachatkun, Nikita Nangia, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. SuperGLUE: A Stickier Benchmark for General-Purpose Language Understanding Systems. In H. Wallach, H. Larochelle, A. Beygelzimer, F. d’Áurelio, N. F. de Aviz, E. Fox, and R. Garnett, editors, *Advances in Neural Information Processing Systems 32*, pages 3261–3275. Curran Associates, Inc., 2019. URL <https://arxiv.org/abs/1905.00537>
- [62] Shuohang Wang, Mo Yu, Xiaoxiao Guo, Zhiguo Wang, Tim Klinger, Wei Zhang, Shiyu Chang, Gerry Tesauro, Bowen Zhou, and Jing Jiang. R³: Reinforced ranker-reader for open-domain question answering. In Sheila A. McIlraith and Kilian Q. Weinberger, editors, *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI-18), the 30th innovative Applications of Artificial Intelligence (IAAI-18), and the 8th AAAI Symposium on Educational Advances in Artificial Intelligence (EAAI-18), New Orleans, Louisiana, USA, February 2-7, 2018*, pages 5981–5988. AAAI Press, 2018. URL <https://www.aaai.org/ocs/index.php/AAAI/AAAI18/paper/view/16712>
- [63] Shuohang Wang, Mo Yu, Jing Jiang, Wei Zhang, Xiaoxiao Guo, Shiyu Chang, Zhiguo Wang, Tim Klinger, Gerald Tesauro, and Murray Campbell. Evidence aggregation for answer re-ranking in open-domain question answering. In *ICLR*, 2018. URL <https://openreview.net/forum?id=rJl3yM-Ab>
- [64] Jason Weston, Sumit Chopra, and Antoine Bordes. Memory networks. In Yoshua Bengio and Yann LeCun, editors, *3rd International Conference on Learning Representations, ICLR 2015, San Diego, CA, USA, May 7-9, 2015, Conference Track Proceedings*, 2015. URL <http://arxiv.org/abs/1410.3916>
- [65] Jason Weston, Emily Dinan, and Alexander Miller. Retrieve and refine: Improved sequence generation models for dialogue. In *Proceedings of the 2018 EMNLP Workshop SCAI: The 2nd*

- 面向搜索的对话式人工智能国际研讨会, 第87 - 92页, 比利时布鲁塞尔, 2018年10月。计算语言学协会。doi: 10.18653/v1/W18 - 5713。网址:
<https://www.aclweb.org/anthology/W18 - 5713>
- [66] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clement Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, Joe Davison, Sam Shleifer, Patrick von Platen, Clara Ma, Yacine Jernite, Julien Plu, Canwen Xu, Teven Le Scao, Sylvain Gugger, Mariama Drame, Quentin Lhoest, and Alexander M. Rush。Huggingface的transformers: 自然语言处理的最新技术。ArXiv, abs/1910.03771, 2019年。
- [67] Shiyue Zhang和Mohit Bansal。解决半监督问答中问题生成的语义漂移问题。在2019年自然语言处理经验方法会议和第9届自然语言处理国际联合会议 (EMNLP - IJCNLP) 论文集, 第2495 - 2509页, 中国香港, 2019年11月。计算语言学协会。doi: 10.18653/v1/D19 - 1253。网址: <https://www.aclweb.org/anthology/D19 - 1253>
- [68] Wanjun Zhong, Jingjing Xu, Duyu Tang, Zenan Xu, Nan Duan, Ming Zhou, Jiahai Wang, and Jian Yin。基于语义级图的事实核查推理。ArXiv, abs/1909.03745, 2019年。网址:
<https://arxiv.org/abs/1909.03745>