

面向知识密集型NLP任务的检索增强生成

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks

Patrick Lewis^{†‡}, Ethan Perez[?], Aleksandra Piktus[†], Fabio Petroni[†], Vladimir Karpukhin[†], Naman Goyal[†], Heinrich Küttler[†], Mike Lewis[†], Wen-tau Yih[†], Tim Rocktäschel^{†‡}, Sebastian Riedel^{†‡}, Douwe Kiela[†]

[†]Facebook AI Research ; [‡]伦敦大学学院 ; [?]纽约大学

plewis@fb.com

摘要

大型预训练语言模型已被证明能够将事实知识存储在其参数中，并在对下游NLP任务进行微调后取得最先进的结果。然而，这类模型访问和精确处理知识的能力仍然有限，因此在知识密集型任务上，其性能落后于专门针对特定任务设计的架构。此外，为其决策提供来源依据以及更新其世界知识，仍是开放性的研究问题。具备可微分访问机制、能访问显式非参数记忆的预训练模型可以克服这一问题，但迄今为止仅在抽取式下游任务中进行过研究。我们探索了一种用于检索增强生成（RAG）的通用微调方案——这类模型将预训练参数记忆与非参数记忆相结合，用于语言生成。我们引入的RAG模型以预训练的序列到序列模型作为参数记忆，以维基百科的稠密向量索引作为非参数记忆，并通过预训练的神经检索器进行访问。我们比较了两种RAG形式：一种在整个生成序列中使用相同的检索段落进行条件化，另一种可以在每个词元处使用不同的段落。我们在广泛的知识密集型NLP任务上对模型进行微调和评估，在三个开放域问答任务上创造了最新最优结果，优于参数化序列到序列模型和专门针对任务的检索抽取架构。对于语言生成任务，我们发现RAG模型生成的语言比最先进的纯参数序列到序列基线更具体、更多样、更真实。

1 引言

预训练神经语言模型已被证明能从数据中学习大量深度知识。它们无需访问任何外部记忆即可做到这一点，因为模型本身就充当了参数化隐式知识库。尽管这一发展令人振奋，但此类模型确实存在一些不足：它们难以轻易扩展或修改其记忆，无法直接为预测提供可解释性，并且可能产生「幻觉」。将参数记忆与非参数（即基于检索的）记忆相结合的混合模型可以解决其中部分问题，因为知识可以被直接修改和扩展，所访问的知识也可以被检查和解释。REALM和ORQA是两个最近提出的模型，它们将掩码语言模型与可微分检索器相结合，展示了令人期待的结果，但仅探索了开放域抽取式问答。在此，我们将参数记忆与非参数记忆的混合机制引入NLP的「主力军」——即序列到序列（seq2seq）模型。

我们通过一种通用微调方法为预训练参数记忆生成模型赋予非参数记忆，称之为检索增强生成（RAG）。我们构建的RAG模型以预训练的seq2seq Transformer作为参数记忆，以维基百科的稠密向量索引作为非参数记忆，并通过预训练的神经检索器进行访问。我们将这些组件组合成一个端到端训练的概率模型（见图1）。检索器（稠密段落检索器DPR）根据输入提供条件化的潜在文档，seq2seq模型（BART）随后以这些潜在文档和输入为条件生成输出。我们使用Top-K近似对潜在文档进行边缘化，既可以基于每个输出（假设同一文档负责所有词元），也可以基于每个词元（不同文档负责不同词元）。与T5或BART类似，RAG可以在任何seq2seq任务上微调，其中生成器和检索器均联合学习。

此前已有大量研究提出通过非参数记忆来丰富系统的架构，这些架构从头针对特定任务训练，例如记忆网络、栈增强网络和记忆层。与之相比，我们探索的是参数记忆组件和非参数记忆组件均经过预训练、并预先加载了大量知识的场景。关键在于，通过使用预训练的访问机制，访问知识的能力无需额外训练即可具备。

我们的结果突显了将参数记忆和非参数记忆与生成相结合用于知识密集型任务的优势——这类任务是人类在没有外部知识来源的情况下无法合理完成的。我们的RAG模型在开放域Natural Questions、WebQuestions和CuratedTrec上取得了最优结果，并在TriviaQA上大幅超越了使用专门预训练目标的近期方法。尽管这些是抽取式任务，我们发现无约束的生成方式超越了以往的抽取方法。对于知识密集型生成，我们在MS-MARCO和Jeopardy问题生成任务上进行了实验，发现我们的模型生成的回复比BART基线更真实、更具体、更多样。对于FEVER事实核查，我们取得了与最先进流水线模型相差4.3%以内的结果，而后者使用了强检索监督信号。最后，我们展示了非参数记忆可以被替换，以便随着世界变化更新模型的知识。

2 方法

我们探索的RAG模型使用输入序列 x 检索文本文档 z ，并在生成目标序列 y 时将其用作额外上下文。如图1所示，我们的模型利用两个组件：(i)

检索器 $p_\eta(z|x)$ ，参数为 η ，给定查询 x 返回文本段落上的（Top-K截断）分布；(ii) 生成器 $p_\theta(y_i|x, z, y_{1:i-1})$ ，参数为 θ ，基于前 $i-1$ 个词元 $y_{1:i-1}$ 的上下文、原始输入 x 和检索到的段落 z ，生成当前词元。

为了端到端地训练检索器和生成器，我们将检索到的文档视为潜在变量。我们提出两种模型，以不同方式对潜在文档进行边缘化，以产生生成文本的分布。第一种方法RAG-Sequence使用同一文档预测每个目标词元；第二种方法RAG-Token可以基于不同文档预测每个目标词元。

2.1 模型

RAG-Sequence模型 RAG-Sequence模型使用同一检索文档来生成完整序列。从技术上讲，它将检索到的文档视为单一潜在变量，通过Top-K近似对其边缘化以得到seq2seq概率 $p(y|x)$ 。具体而言，使用检索器检索Top-K个文档，生成器对每个文档产生输出序列概率，然后进行边缘化：

$$p_{\text{RAG-Seq}}(y|x) \approx \sum_{z \in \text{top-k}(p(\cdot|x))} p_\eta(z|x) \cdot p_\theta(y|x, z) = \sum_{z \in \text{top-k}(p(\cdot|x))} p_\eta(z|x) \cdot \prod_i p_\theta(y_i|x, z, y_{1:i-1})$$

RAG-Token模型 在RAG-Token模型中，我们可以为每个目标词元抽取不同的潜在文档并相应进行边缘化。这允许生成器在生成答案时从多个文档中提取内容。具体而言，使用检索器检索Top-K个文档，生成器对每个文档产生下一个输出词元的分布，然后边缘化，再对下一个输出词元重复此过程：

$$p_{\text{RAG-Token}}(y|x) \approx \prod_i \sum_{z \in \text{top-k}(p(\cdot|x))} p_\eta(z|x) \cdot p_\theta(y_i|x, z_i, y_{1:i-1})$$

最后，我们注意到RAG可用于序列分类任务，只需将目标类别视为长度为1的目标序列，此时RAG-Sequence和RAG-Token是等价的。

2.2 检索器：DPR

检索组件 $p_\eta(z|x)$ 基于DPR。DPR采用双编码器架构：

$$p_\eta(z|x) \propto \exp(d(z)^T q(x)), \text{ 其中 } d(z) = \text{BERT}_d(z), q(x) = \text{BERT}_q(x)$$

其中 $d(z)$ 是由基于 $BERT_{BASE}$ 的文档编码器生成的文档稠密表示， $q(x)$ 是由同样基于 $BERT_{BASE}$ 的查询编码器生成的查询表示。计算 $\text{top-k}(p_{\eta}(\cdot|x))$ ——即具有最高先验概率 $p_{\eta}(z|x)$ 的 k 个文档列表——是一个最大内积搜索（MIPS）问题，可以在次线性时间内近似求解。我们使用DPR的预训练双编码器来初始化我们的检索器并构建文档索引。该检索器经过训练，用于检索包含TriviaQA和Natural Questions问题答案的文档。我们将文档索引称为非参数记忆。

2.3 生成器：BART

生成器组件 $p_{\theta}(y_i|x,z,y_{1:i-1})$ 可以使用任意编码器-解码器建模。我们使用BART-large，这是一个拥有4亿参数的预训练seq2seq Transformer。在从BART生成时，为了将输入 x 与检索内容 z 相结合，我们直接将二者拼接。BART使用去噪目标和多种不同的加噪函数进行预训练，在多种生成任务上取得了最先进的结果，并优于同等规模的T5模型。我们将BART生成器参数 θ 称为参数记忆。

2.4 训练

我们联合训练检索器和生成器组件，无需对应检索哪个文档进行任何直接监督。给定由输入/输出对 (x_j, y_j) 组成的微调训练语料库，我们使用Adam随机梯度下降最小化每个目标的负边缘对数似然 $\sum_j -\log p(y_j|x_j)$ 。在训练过程中更新文档编码器 $BERT_d$ 的代价很高，因为这需要像REALM在预训练期间那样周期性地更新文档索引。我们发现此步骤对于获得强性能并不必要，因此保持文档编码器（和索引）固定，只微调查询编码器 $BERT_q$ 和BART生成器。

2.5 解码

在测试时，RAG-Sequence和RAG-Token需要不同的方式来近似 $\arg\max_y p(y|x)$ 。

RAG-Token RAG-Token模型可以视为具有如下转移概率的标准自回归seq2seq生成器： $p'_{\theta}(y_i|x,y_{1:i-1}) = \sum_{z \in \text{top-k}(p(\cdot|x))} p_{\eta}(z|x) \cdot p_{\theta}(y_i|x,z,y_{1:i-1})$ 。对于解码，我们可以将 p'_{θ} 代入标准束搜索解码器。

RAG-Sequence 对于RAG-Sequence，似然 $p(y|x)$ 不能分解为传统的逐词元似然，因此无法通过单次束搜索求解。我们转而对每个文档 z 分别运行束搜索，使用 $p_{\theta}(y_i|x,z,y_{1:i-1})$ 对每个假设进行评分。这会产生一组假设集合 Y ，其中某些假设可能未出现在所有文档的束中。为估计假设 y 的概率，我们对 y 未出现在束中的每个文档 z 额外运行一次前向传播，将生成器概率与 $p_{\eta}(z|x)$ 相乘，然后在束间对边缘概率求和。我们将此解码过程称为「彻底解码」。对于更长的输出序列， $|Y|$ 可能变得很大，需要多次前向传播。为了更高效的解码，我们可以进一步近似：对于在束搜索中未从 (x, z_i) 生成的 y ，令 $p_{\theta}(y|x,z_i) \approx 0$ ，从而避免在候选集 Y 生成后再次进行额外前向传播。我们将此解码过程称为「快速解码」。

3 实验

我们在广泛的知识密集型任务中对RAG进行实验。在所有实验中，我们使用单一维基百科转储作为非参数知识来源。遵循Lee等人和Karpukhin等人的做法，我们使用2018年12月的转储。每篇维基百科文章被分割为不相交的100词块，总计2100万个文档。我们使用文档编码器为每个文档计算嵌入，并使用FAISS构建单一MIPS索引，采用分层可导航小世界近似以实现快速检索。在训练期间，我们为每个查询检索Top- k 个文档，其中 $k \in \{5, 10\}$ 。我们使用开发集数据为测试时设置 k 。

3.1 开放域问答

开放域问答（QA）是重要的实际应用场景，也是知识密集型任务的常见测试平台。我们将问题和答案视为输入-输出文本对(x, y)，通过直接最小化答案的负对数似然来训练RAG。我们将RAG与流行的抽取式QA范式进行比较，后者从检索到的文档中抽取答案跨度，主要依赖非参数知识。我们还与「闭卷QA」方法进行比较，该方法与RAG一样生成答案，但不利用检索，完全依赖参数知识。我们考虑四个流行的开放域QA数据集：Natural Questions（NQ）、TriviaQA（TQA）、WebQuestions（WQ）和CuratedTrec（CT）。

3.2 抽象式问答

RAG模型可以超越简单的抽取式QA，以自由形式的抽象文本生成来回答问题。为了在知识密集型设置中测试RAG的自然语言生成（NLG）能力，我们使用MSMARCO NLG任务v2.1。该任务包含问题、为每个问题从搜索引擎检索到的十篇金标段落，以及从检索段落中标注的完整句子答案。我们不使用提供的段落，只使用问题和答案，将MSMARCO视为开放域抽象QA任务。

3.3 Jeopardy问题生成

为了在非问答设置中评估RAG的生成能力，我们研究了开放域问题生成。我们提出了更具挑战性的Jeopardy问题生成任务，而非使用标准开放域QA任务中典型的简短问题。Jeopardy是一种不寻常的格式：需要根据关于某个实体的事实来猜测该实体。例如，「世界杯」是「1986年墨西哥成为第一个举办该国际体育赛事两次的国家」这一问题的答案。由于Jeopardy问题是精确的事实性陈述，以答案实体为条件生成Jeopardy问题构成了一项具有挑战性的知识密集型生成任务。我们使用SearchQA的划分，包含10万训练、1.4万开发和2.7万测试样本。我们使用Q-BLEU-1指标进行评估，这是BLEU的一个变体，对实体匹配赋予更高权重，与人类判断的相关性优于标准指标。

3.4 事实核查

FEVER任务要求对自然语言声明进行分类：是被维基百科支持、被反驳，还是信息不足以判断。该任务需要从维基百科检索与声明相关的证据，然后对这些证据进行推理以分类声明是否为真。FEVER是一个将检索问题与复杂的蕴含推理任务相结合的任务，也是探索RAG模型处理分类而非生成能力的合适测试平台。我们将FEVER类标签映射到单一输出词元，直接使用声明-类别对进行训练。关键在于，与大多数其他FEVER方法不同，我们不使用检索证据的监督信号。

4 结果

4.1 开放域问答

表1展示了RAG与最先进模型的结果对比。在全部四个开放域QA任务上，RAG均创造了新的最优结果。RAG兼具「闭卷」（纯参数）方法的生成灵活性和基于检索的「开卷」方法的性能优势。与REALM和T5+SSM不同，RAG无需昂贵的专门「显著跨度掩码」预训练即可取得强劲结果。值得注意的是，RAG的检索器使用DPR的检索器初始化，后者在Natural Questions和TriviaQA上使用了检索监督信号。RAG与使用基于BERT的「交叉编码器」对文档重排序以及抽取式阅读器的DPR QA系统相比同样具有优势。RAG表明，既不需要重排序器，也不需要抽取式阅读器，即可实现最先进的性能。

模型	NQ	TQA	WQ	CT
----	----	-----	----	----

闭卷	T5-11B	34.5	— / 50.1	37.4	—
	T5-11B+SSM	36.6	— / 60.5	44.7	—
开卷	REALM	40.4	— / —	40.7	46.8
	DPR	41.5	57.9 / —	41.1	50.6
	RAG-Token	44.1	55.2 / 66.1	45.5	50.0
	RAG-Seq.	44.5	56.8 / 68.0	45.2	52.2

表1：开放域QA测试集得分。TQA左列为开放域QA标准测试集，右列为TQA-Wiki测试集。

生成答案相比抽取答案存在若干优势。包含答案线索但不逐字包含答案的文档仍能有助于生成正确答案，这在标准抽取方法中是不可能的，从而可以更有效地对文档进行边缘化。此外，RAG即使在检索到的文档中不包含正确答案的情况下也能生成正确答案，在NQ此类情况下准确率达到11.8%，而抽取模型的得分为0%。

4.2 抽象式问答

如表2所示，RAG-Sequence在开放域MS-MARCO NLG任务上比BART高出2.6个BLEU分和2.6个Rouge-L分。考虑到(i)最先进模型可以访问包含生成参考答案所需具体信息的金标段落，(ii)许多问题在没有金标段落的情况下无法回答，(iii)并非所有问题都能仅凭维基百科回答，RAG接近最先进模型的性能令人印象深刻。

4.3 Jeopardy问题生成

表2显示，在Jeopardy问题生成上，RAG-Token优于RAG-Sequence，两个模型均在Q-BLEU-1指标上超过BART。表4展示了对452对BART和RAG-Token生成结果的人工评估。评估者仅在7.1%的案例中认为BART比RAG更真实，而在42.7%的案例中认为RAG更真实，在另外17%的案例中两者均真实，这清楚地证明了RAG在该任务上相对于最先进生成模型的有效性。评估者还发现RAG的生成结果更加具体，且差距显著。

4.4 事实核查

表2展示了我们在FEVER上的结果。对于三分类任务，RAG得分与最先进模型相差4.3%以内，而后者是使用特定领域架构和大量工程设计的复杂流水线系统，并借助中间检索监督进行训练，而RAG则无需此类监督。对于二分类任务，我们与Thorne和Vlachos进行比较，他们在给定金标证据句的条件下训练RoBERTa对声明进行真假分类。尽管RAG只获得声明本身并自行检索证据，其准确率仍与该模型相差2.7%以内。

4.5 补充结果

生成多样性 通过计算不同ngram与总ngram的比率来考查生成多样性。表5显示，RAG-Sequence的生成结果比RAG-Token更多样，而两者均比BART显著更多样，且无需任何促进多样性的解码策略。

检索消融实验 RAG的关键特性是学会为任务检索相关信息。为评估检索机制的有效性，我们进行了在训练期间冻结检索器的消融实验。如表6所示，在所有任务上，可学习检索均能提升结果。我们将RAG的稠密检索器与基于词重叠的BM25检索器进行比较。对于FEVER，BM25表现最佳，这可能是因为FEVER声明以实体为中心，因此适合基于词重叠的检索。可微分检索在所有其他任务上均能提升结果，尤其在开放域QA中效果显著。

索引热替换 非参数记忆模型（如RAG）的一个优势是，知识可以在测试时轻松更新。纯参数模型（如T5或BART）需要进一步训练才能随世界变化更新其行为。为此，我们使用2016年12月的DrQA维基百科转储构建索引，并将RAG使用该索引的输出与使用主实验（2018年12月）更新索引的输出进行比较。我们准备了一份在这两个日期之间更换过的82位世界领导人名单，使用模板'Who is {position}?'（例如'谁是秘鲁总统?'）查询我们的NQ RAG模型。结果显示，使用2016年索引时，RAG对2016年世界领导人的回答准确率为70%，使用2018年索引时对2018年世界领导人的准确率为68%。索引与查询时间不匹配时准确率很低（使用2018年索引查询2016年领导人仅12%，反之仅4%）。这说明，仅需替换非参数记忆即可更新RAG的世界知识。

检索文档数量的影响 模型以5或10篇潜在文档进行训练，两者之间未观察到显著性能差异。我们可以在测试时灵活调整检索文档数量，这会影响性能和运行时间。图3显示，对于RAG-Sequence，测试时检索更多文档可单调提升开放域QA结果，而RAG-Token的性能在检索10篇文档时达到峰值。

5 相关工作

单任务检索 先前工作表明，检索可以在多种NLP任务中单独提升性能，包括开放域问答、事实核查、事实补全、长形式问答、维基百科文章生成、对话、翻译和语言建模。我们的工作统一了将检索引入各个任务的先前成功经验，展示了单一基于检索的架构能够在多个任务上取得强劲性能。

NLP通用架构 NLP通用架构的先前工作在不使用检索的情况下取得了巨大成功。单一预训练语言模型在微调后已被证明能在GLUE基准的各种分类任务上取得强劲性能。GPT-2后来表明，单一从左到右的预训练语言模型可以在判别式和生成式任务上均取得强劲性能。为进一步提升，BART和T5提出了利用双向注意力的单一预训练编码器-解码器模型。我们的工作旨在通过学习检索模块来增强预训练生成语言模型，从而扩展单一统一架构可处理的任务范围。

可学习检索 在信息检索领域，以及最近使用类似于我们的预训练神经语言模型方面，学习检索文档有大量相关工作。部分工作通过搜索、强化学习或类似我们工作的潜在变量方法，优化检索模块以辅助特定下游任务（如问答）。这些工作利用不同的基于检索的架构和优化技术在单一任务上取得强劲性能，而我们展示了单一基于检索的架构可以在多种任务上微调并取得强劲性能。

基于记忆的架构 我们的文档索引可以视为神经网络关注的大型外部记忆，类似于记忆网络。并发工作学习为输入中的每个实体检索训练嵌入，而非像我们的工作那样检索原始文本。我们记忆的一个关键特性是由原始文本而非分布式表示构成，这使得记忆既(i)人类可读，赋予模型一定的可解释性，也(ii)人类可写，使我们能够通过编辑文档索引来动态更新模型的记忆。

检索-编辑方法 我们的方法与检索-编辑风格的方法有一定相似之处，后者针对给定输入检索相似的训练输入-输出对，然后进行编辑以提供最终输出。这类方法在机器翻译和语义解析等多个领域取得了成功。我们的方法存在若干差异，包括更强调聚合多个检索内容片段，而非对检索项进行轻度编辑，以及学习潜在检索和检索证据文档（而非相关训练对）。

6 讨论

在本文中，我们提出了能够访问参数记忆和非参数记忆的混合生成模型。我们展示了RAG模型在开放域QA上取得了最先进的结果。我们发现，人们更倾向于RAG的生成结果而非纯参数的BART，认为RAG更真实、更具体。我们对可学习检索组件进行了深入调查，验证了其有效性，并说明了如何通过热

替换检索索引来更新模型而无需重新训练。在未来工作中，探索两个组件是否可以从头联合预训练（使用类似于BART的去噪目标或其他目标）可能会有所收获。我们的工作为研究参数记忆与非参数记忆如何交互以及如何最有效地组合它们开辟了新的研究方向，并展示了在广泛NLP任务中应用的潜力。

更广泛影响

与先前工作相比，本研究提供了若干积极的社会效益：由于更强地以真实事实知识（维基百科）为基础，模型产生「幻觉」的情况更少，生成内容更真实，并提供了更多可控性和可解释性。RAG可以应用于多种对社会直接有益的场景，例如为其配备医学索引并提问相关开放域问题，或帮助人们更高效地工作。

这些优势也伴随着潜在的不足：维基百科或任何潜在的外部知识来源都可能不完全真实，且不可避免地带有偏见。由于RAG可被用作语言模型，GPT-2所提出的类似担忧在此同样适用（尽管程度较轻），包括可能被用于生成滥用性、虚假或误导性内容；冒充他人；或自动化生成垃圾邮件/网络钓鱼内容。先进语言模型在未来几十年也可能导致各类工作的自动化。为降低这些风险，可以部署AI系统来对抗误导性内容和自动化垃圾/网络钓鱼行为。

致谢

作者感谢审稿人提供深思熟虑的建设性反馈，以及HuggingFace在开源RAG模型运行代码方面的帮助。作者还感谢Kyunghyun Cho和Sewon Min提供的富有成效的讨论和建议。

资助说明：EP感谢NSF研究生奖学金的支持。PL由FAIR博士项目资助。本工作由Facebook资助。