



福建理工大学
FUJIAN UNIVERSITY OF TECHNOLOGY

本科毕业设计（论文）开题报告

交通运输		学院	信息管理与信息系统	专业
设计（论文）题目		基于大语言模型的缺陷检测 AGENT 设计与实现		
学生姓名	颜益炜		学号	3221806228
起迄日期		2026. 3. 6-2026. 6. 28		
设计（论文）地点		校内		
指导教师		郑积仕		

2026 年 03 月 15 日

毕业设计（论文）开题报告

1.文献综述

近年来，大语言模型、检索增强生成和智能体技术的发展，为工业检测场景中的智能交互与辅助决策提供了新的实现路径。Vaswani 等提出的 Transformer 架构奠定了现代大语言模型的技术基础，使模型在上下文理解和文本生成方面具备较强能力[1]；Lewis 等提出的 RAG 方法，将外部知识检索与文本生成结合起来，提升了知识密集型任务中的准确性、可追溯性和可更新性[2]。在此基础上，Self-RAG 和 Graph RAG 等研究进一步说明，检索结果、反思机制和结构化知识组织可以共同提高生成结果的可靠性[4][5]。对于 DAC-3D 缺陷检测场景而言，参数说明、检测流程、设备状态和缺陷判定均依赖专业文档，因此仅依赖模型参数记忆难以满足工业应用对可靠性的要求，检索增强生成提供了较合适的技术基础。

在智能体研究方面，Yao 等提出的 ReAct 框架表明，大语言模型不仅可以生成文本，还可以在任务执行过程中调用外部工具、获取反馈并调整推理过程[3]。这说明，面向 DAC-3D 检测流程构建缺陷检测 AGENT，不能停留在普通问答，而应进一步组织工具调用、状态读取、命令审批和结果解释等能力。Zheng 等关于生产与物流数字助手的研究也表明，工业数字助手的价值不仅在于知识查询，还体现在流程协调、信息获取和现场辅助决策等方面[6]。因此，针对 DAC-3D 场景设计一个集文档问答、参数解释、自然语言操作、结果解读、状态查询和离线检测于一体的缺陷检测 AGENT，具有较强的研究价值和应用意义。

从工程实现角度看，FastAPI 和 React 等 Web 技术已经能够支撑后端接口服务和网页端交互界面的快速构建[7][8]。本文采用网页端助手的方式，使系统可以脱离 DAC-3D 主程序单独运行和测试，也可以由主系统跳转访问。与此同时，系统通过状态文件桥接读取 DAC-3D 主窗口写出的 JSON 状态文件，通过受控命令桥接完成命令预览和提交边界控制，在不改动主检测算法的前提下实现低侵入式集成。综上，本课题既具有大语言模型与工业软件结合的研究意义，也具有较明确的工程实现条件。

2.毕业设计（论文）要研究或解决的问题

本课题拟研究并解决以下问题：一是如何避免大语言模型在工业检测场景中出现回答脱离文档依据、专业性不足的问题；二是如何将用户自然语言输入准确映射为问答、操作、结果解读、指导建议、状态查询、离线检测和停止检测等不同任务；三是如何将 DAC-3D 返回的结构化检测结果转化为操作员易于理解的中文解释；四是如何通过状态文件桥接读取 DAC-3D 主系统实时状态，并把它作为网页端助手回答“当前检测状态是什么”的依据；五是如何使系统具备独立运行、独立测试以及由 DAC-3D 主系统跳转访问的能力。针对上述问题，本课题拟采用“知识库构建+检索增强生成+Agent 编排+意图识别+结构化命令生成+状态文件桥接+结果解析+前后端分离界面”的总体方法，构建一个面向 DAC-3D 检测流程的任务型智能助手。

3.设计步骤与方法

本课题的设计将按照“需求分析—知识构建—任务实现—状态桥接—前端交互—系统测试”的步骤展开。前期分析 DAC-3D 检测流程中的典型用户需求，明确系统的核心任务边界；随后整理说明手册、参数文档、FAQ 和缺陷规则等资料，完成知识库清洗、分块、向量化与索引持久化；在任务实现阶段，构建面向不同任务的提示模板，实现文档问答、操作指导、结果解释与命令补全链路；再完成意图分类、结构化命令生成、检测结果解析、状态文件桥接和受控命令桥接模块；最后设计网页端对话界面，并通过典型场景测试验证系统在问答准

确性、命令正确性、状态读取和结果解释可读性方面的效果。

4.拟采用的方法

本课题拟采用以下方法：一是采用文档分块与向量索引方法构建 DAC-3D 本地知识库；二是采用检索增强生成方法，对问答、指导和结果解释类任务进行知识约束；三是采用意图分类与规则校验方法，对自然语言操作请求生成结构化命令预览；四是采用状态文件桥接方法读取 DAC-3D 主系统实时状态，避免额外端口和对主检测算法的侵入；五是采用结构化结果解析与规则解释方法，对缺陷检测结果生成“结论+依据+建议”的可解释输出；六是借鉴 ReAct 思想，构建“识别目标—调用模块—生成结果—反馈用户”的 AGENT 执行流程；七是采用 FastAPI 与 React/Vite 前后端分离方案实现可独立运行、可测试、可由主系统跳转访问的网页端原型。

5.设计的可实现性分析

本课题具有较好的可实现性。理论上，大语言模型、RAG、智能体组织机制和工业数字助手研究均已有较成熟成果作为支撑；工程上，系统可以分解为知识库、检索、Agent 编排、意图识别、命令生成、状态桥接、结果解析和界面展示等相对独立的模块，便于逐步实现与联调；开发条件上，Python 后端与 Web 前端技术栈成熟，适合在本科毕业设计周期内完成原型开发；数据条件上，DAC-3D 手册、参数说明、FAQ、缺陷规则和主系统状态文件可作为明确输入；风险控制上，可通过检索增强、来源展示、规则校验、路径白名单、确认机制、状态文件桥接和 mock 运行时等方式降低模型幻觉、知识污染和设备接口风险。因此，在现有技术条件和开发周期下，完成本课题的系统设计与原型实现具有较强可行性。

参考文献（GB/T 7714 格式）

VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30. Red Hook: Curran Associates, 2017:5998-6008.

LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems 33. Red Hook: Curran Associates, 2020:9459-9474.

YAO S, ZHAO J, YU D, et al. ReAct: Synergizing reasoning and acting in language models[EB/OL]. (2022-10-06)[2026-05-16]. <https://arxiv.org/abs/2210.03629>.

ASAI A, WU Z, WANG Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[C]//Proceedings of the Twelfth International Conference on Learning Representations. Vienna: ICLR, 2024.

EDGE D, TRINH H, CHENG N, et al. From local to global: A graph RAG approach to query-focused summarization[EB/OL]. (2024-04-20)[2026-05-24]. <https://arxiv.org/abs/2404.16130>.

ZHENG T, GROSSE E H, MORANA S, et al. A review of digital assistants in production and logistics: Applications, benefits, and challenges[J]. International Journal of Production Research, 2024, 62(21):8022-8048.

TIANGOLO S. FastAPI documentation[EB/OL]. [2026-05-19]. <https://fastapi.tiangolo.com/>.

META PLATFORMS, INC. React documentation[EB/OL]. [2026-05-19]. <https://react.dev/>.

指导教师意见（对课题的深度、广度及工作量的意见和对毕业设计（论文）结果的预测）：

本课题深度、广度、工作量适中，可以作为信息管理与信息系统专业本科毕业生毕业设计课题。

指导教师

2026 年 3 月 15 日

审批意见：

通过

教研室主任

2026 年 3 月 15 日

说明：开题报告作为毕业设计（论文）答辩委员会对学生答辩资格审核的依据材料之一，此报告应在导师指导下，由学生填写，经导师签署意见及教研室主任审批后生效。